RAPPORT DE STAGE

Agent IA d'extraction et de qualification d'entreprises B2B — Luxembourg

Pipeline multi-agents : extraction · recherche OpenCorporates · filtrage B2B · raisonnement LLM

INPT × **3LM Solutions, Tunisie**

Réalisé par : Mohamed EL HARCHALI

Encadrant — Chef de projet : Saidi Souhir

CONTEXTE DU STAGE

Automatiser la qualification B2B des entreprises

Il est nécessaire d'identifier rapidement, parmi les entreprises enregistrées au Luxembourg, celles qui opèrent en B2B et de répondre à des questions précises sur ces entreprises — sans recherche manuelle.

Manuel & lent

Recherche entreprise par entreprise

Données éparses

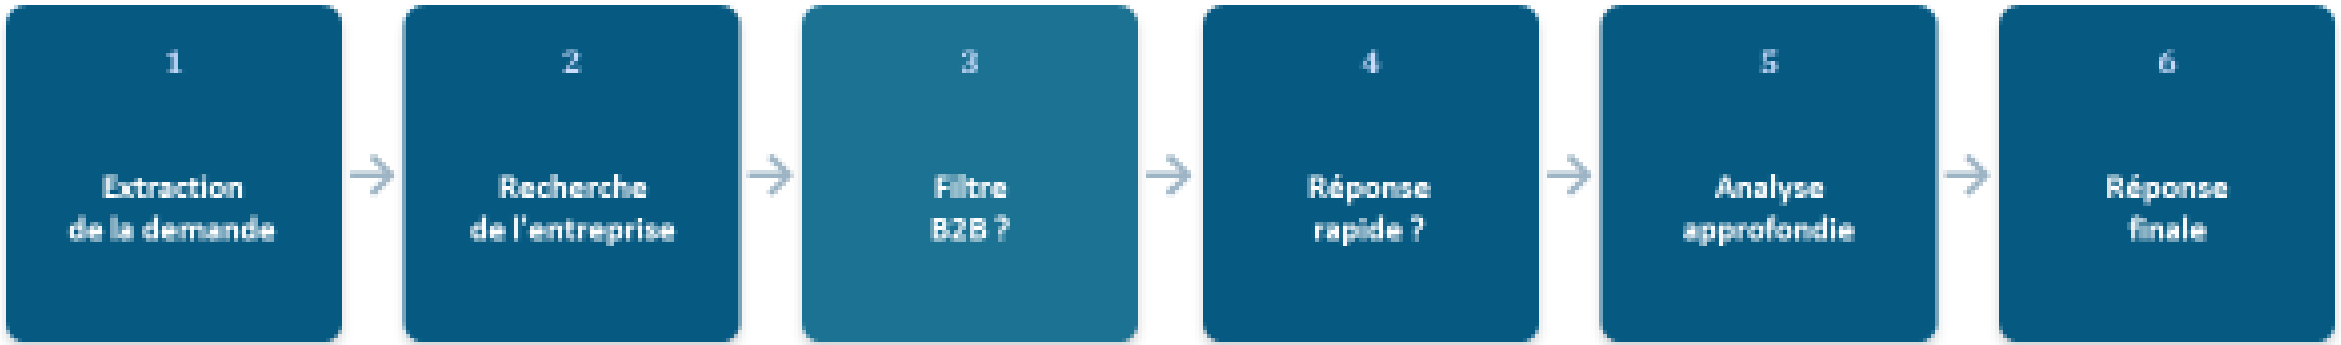
Registres, statuts, statements officiels

Besoin d'un agent

Automatisé, traçable, fiable

ARCHITECTURE

Un pipeline en 6 étapes



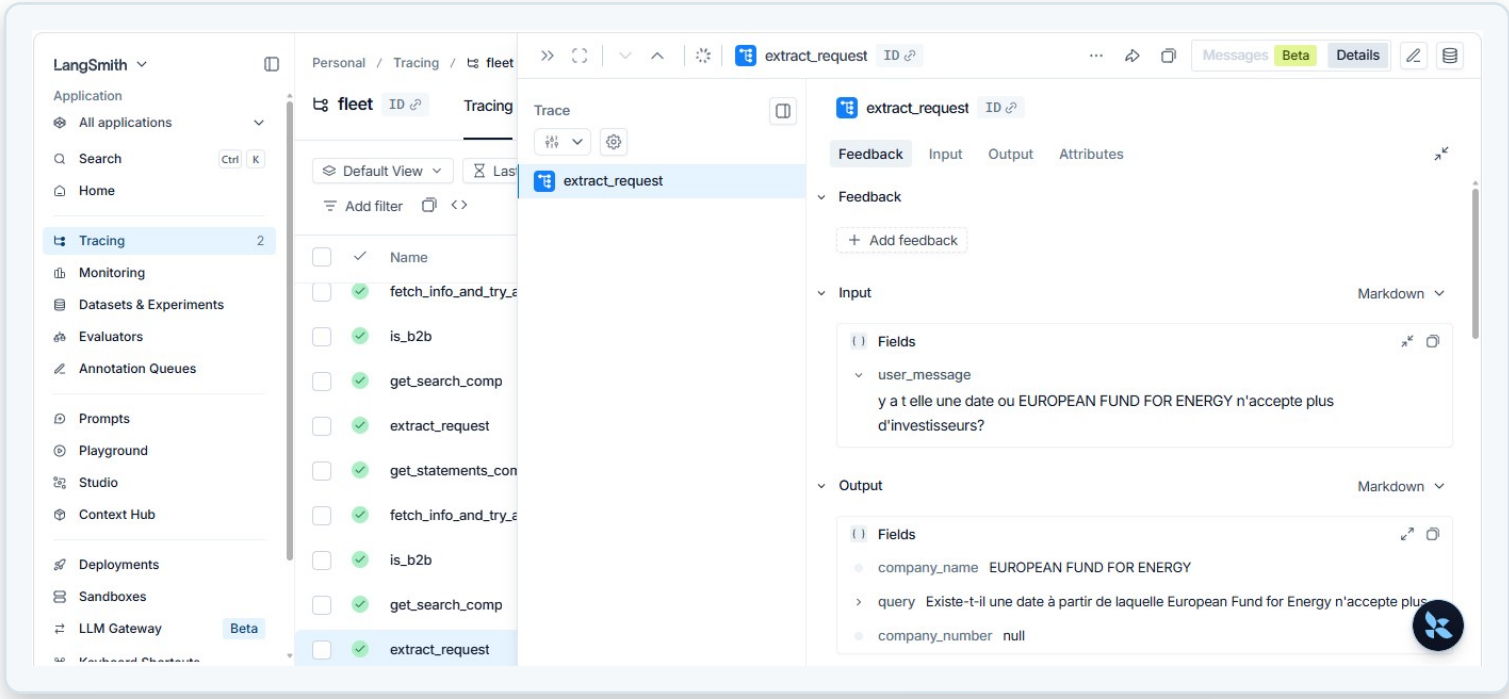
Chaque étape est tracée dans LangSmith — 3 LLM différents collaborent : Ollama (gpt-oss:120b), Google AI Mode (via SerpApi) et NVIDIA Nemotron.

1

ÉTAPE 1 — OLLAMA (GPT-OSS)

Comprendre la demande

Le premier LLM lit la question du client et en extrait : la question reformulée, le nom de l'entreprise et son numéro si connu.



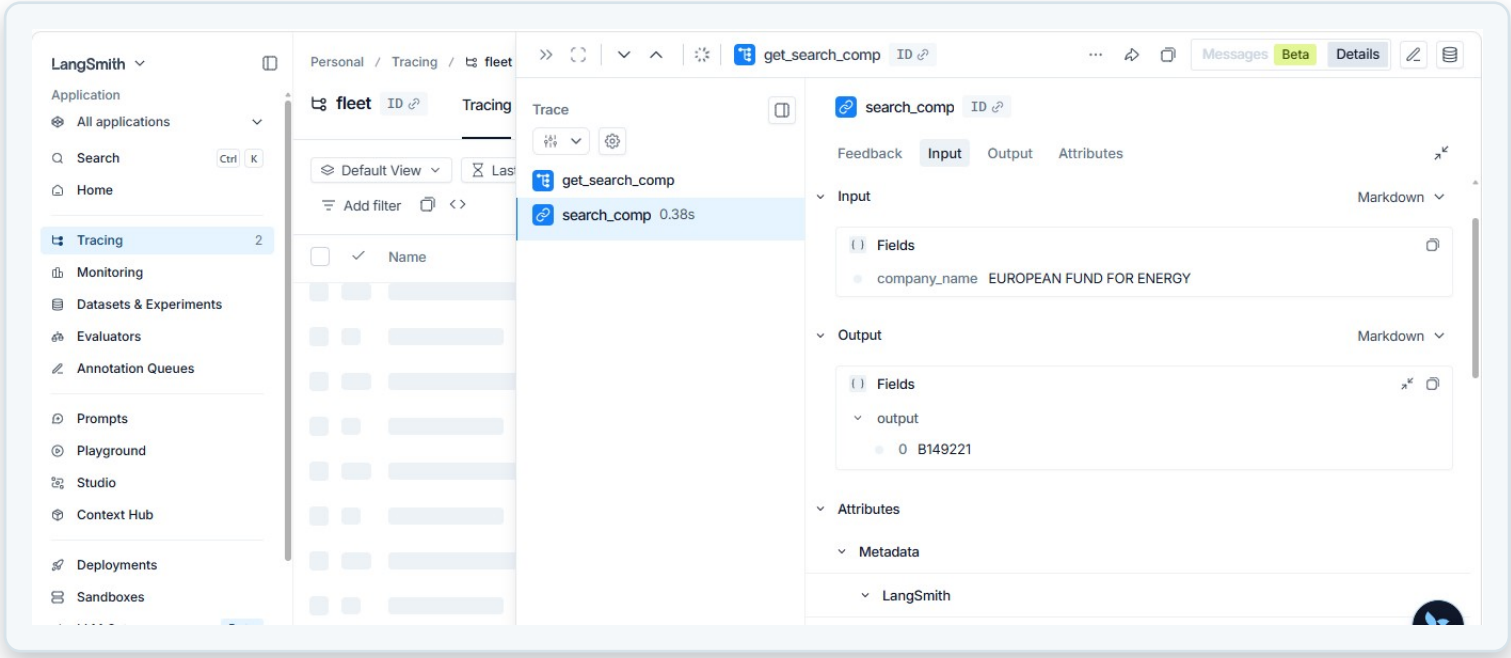
Trace LangSmith — extract_request

2

ÉTAPE 2 — OPENCORPORATES API

Retrouver l'entreprise

À partir du nom extrait, l'agent interroge OpenCorporates et récupère le numéro d'entreprise (RCS) officiel au Luxembourg.



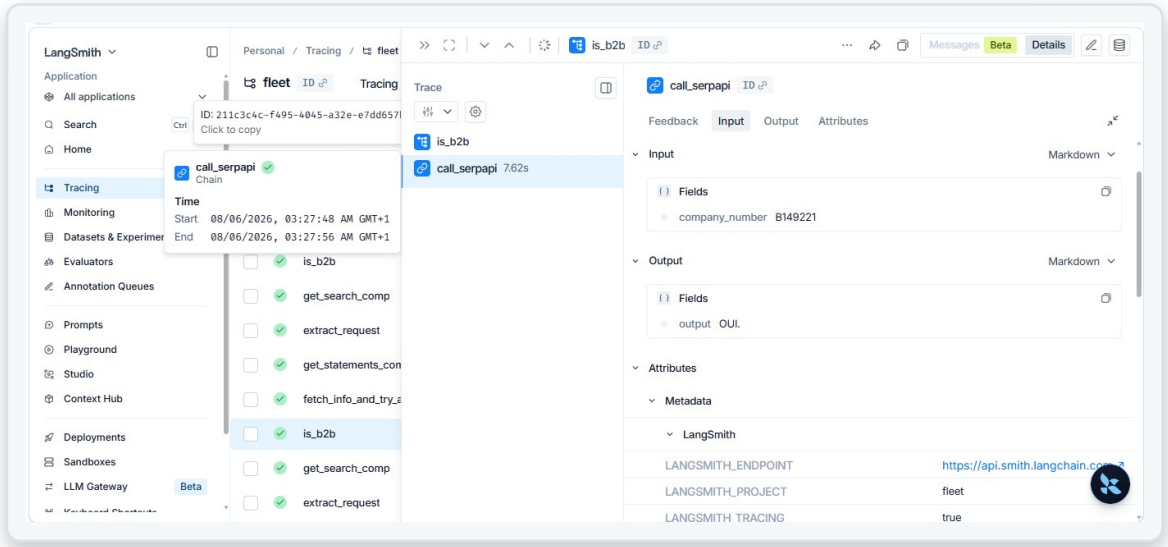
Trace LangSmith — get_search_comp / search_comp

3

ÉTAPE 3 — GOOGLE AI MODE (SERPAPI)

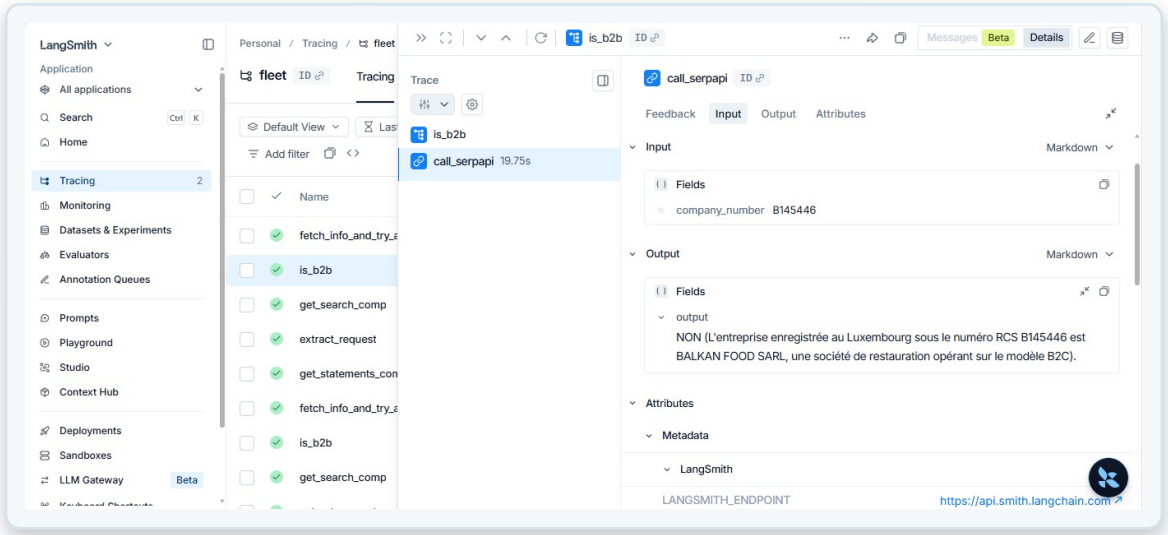
Filtrer : l'entreprise est-elle B2B ?

Entreprise B2B → le pipeline continue



OUI → continue

Entreprise B2C → le pipeline s'arrête



NON → stop

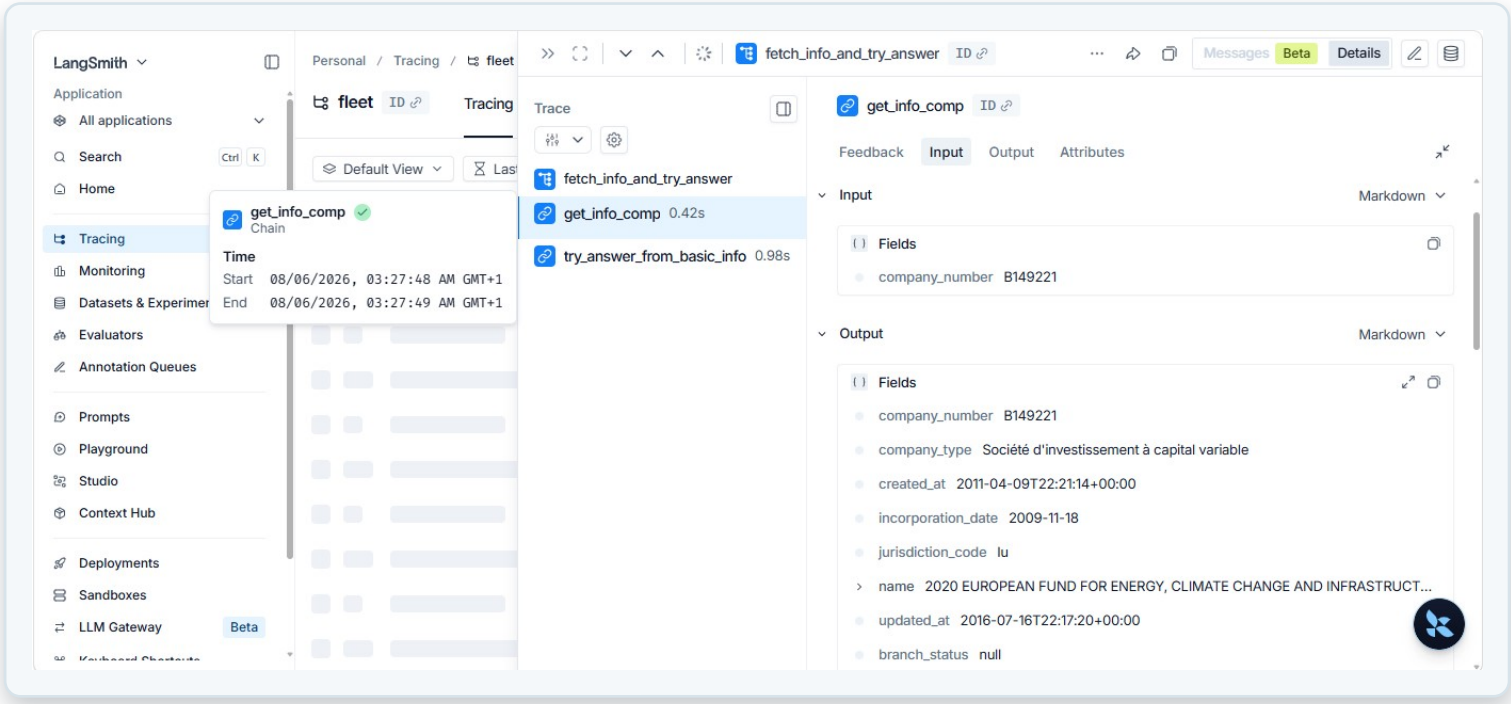
Un deuxième LLM interroge le web pour qualifier l'entreprise avant de poursuivre — seules les entreprises B2B sont traitées plus loin.

4

ÉTAPE 4 — OPENCORPORATES API

Récupérer les infos de base

En parallèle du filtre B2B, l'agent récupère les informations officielles : type, statut, date de constitution…



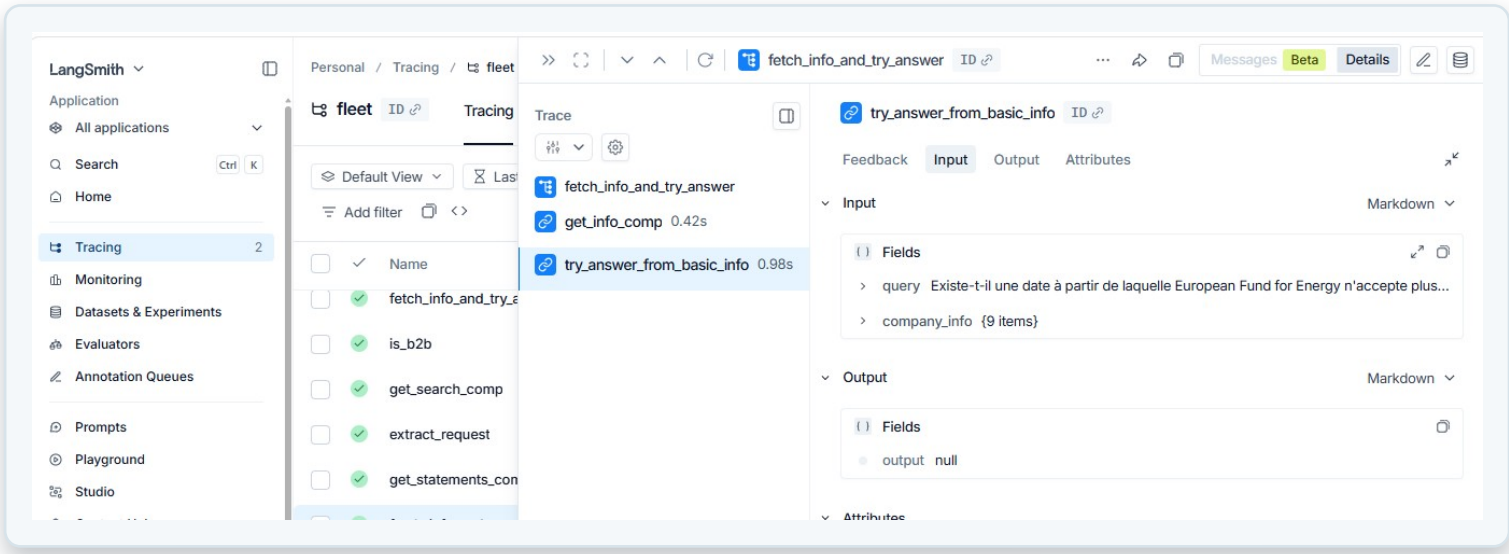
Trace LangSmith — fetch_info_and_try_answer / get_info_comp

5

ÉTAPE 5 — OLLAMA (GPT-OSS)

Ces infos suffisent-elles déjà ?

Le LLM essaie de répondre avec les infos de base seules. Si la question est plus précise (ex : une date d'événement), il renvoie « aucune réponse » — une recherche plus profonde est alors lancée.



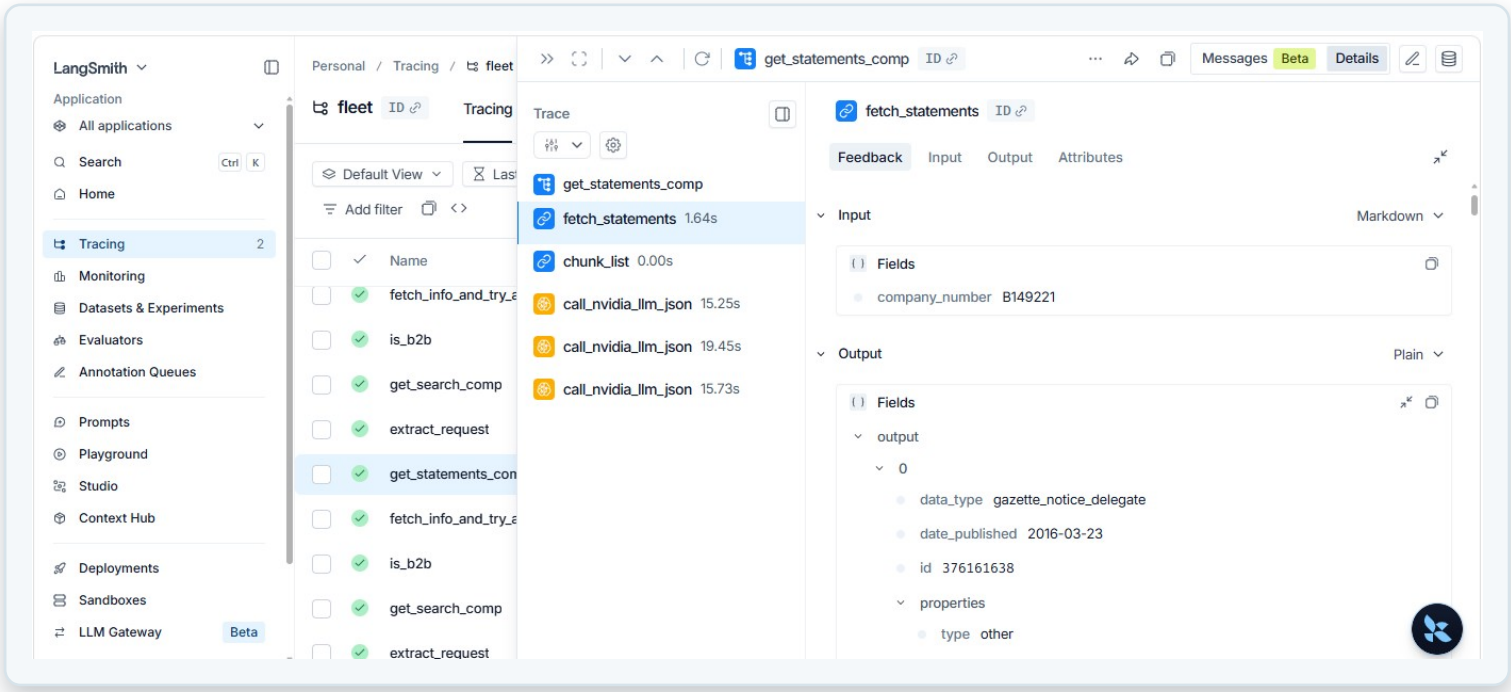
Trace LangSmith — try_answer_from_basic_info (output : null)

6

ÉTAPE 6 — NVIDIA NEMOTRON

Analyser les statements officiels

L'historique complet de l'entreprise (statements OpenCorporates) est découpé en lots (« chunks ») et confié à un troisième LLM, qui les examine un à un.



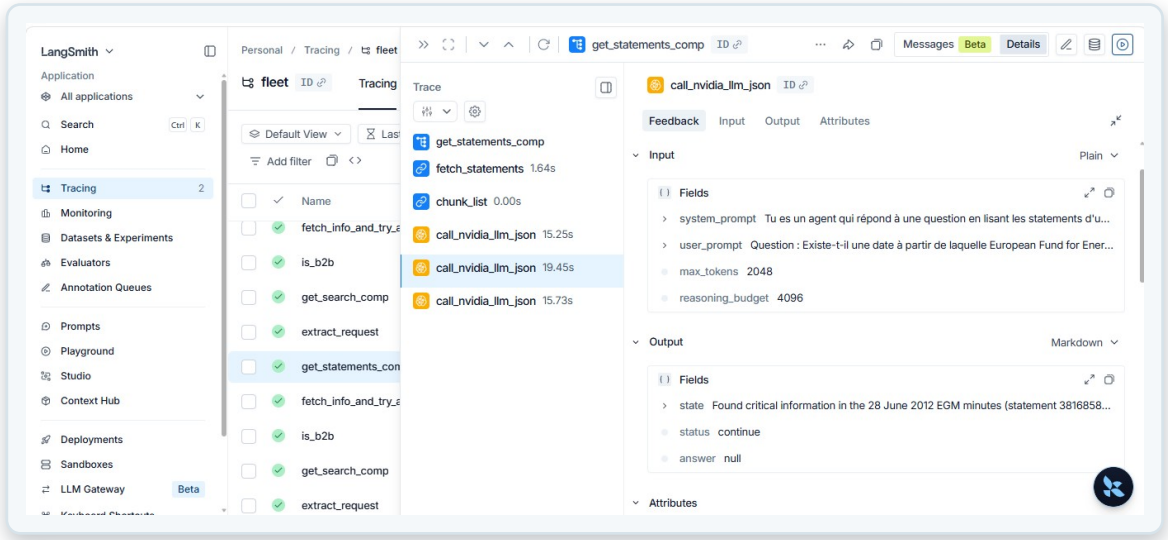
Trace LangSmith — get_statements_comp / fetch_statements

7

ÉTAPE 6 (SUITE)

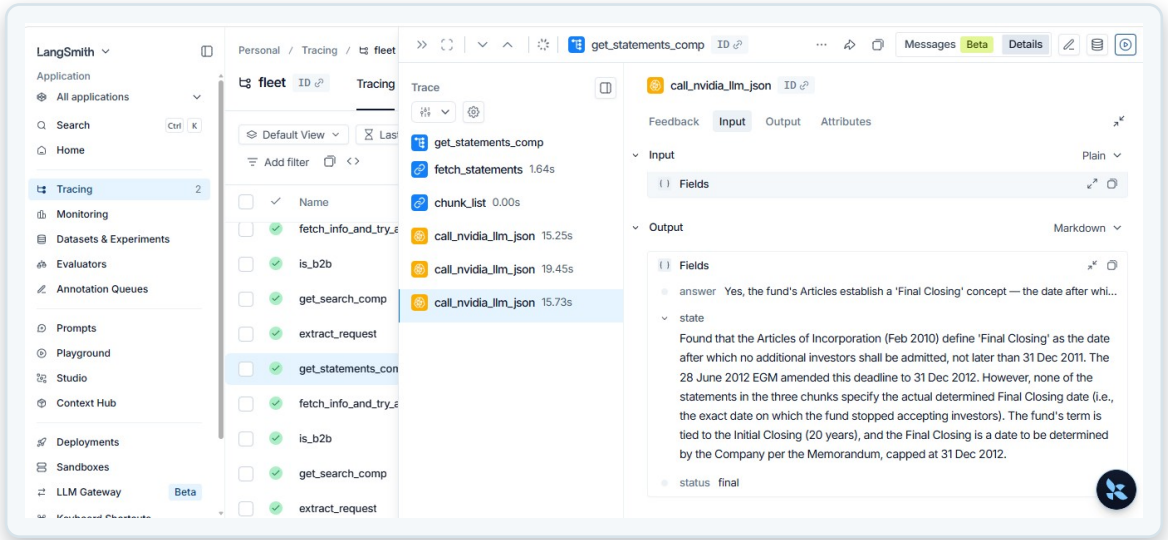
Un raisonnement qui avance chunk par chunk

Chunk 2 : information clé trouvée



status : continue

Chunk 3 : réponse complète



status : final

L'agent décide lui-même s'il doit lire un chunk supplémentaire («continue») ou s'il peut conclure («final»).

LIMITE IDENTIFIÉE

Une couverture de données qui s'arrête en 2016

Les statements OpenCorporates pour le Luxembourg proviennent des publications du Mémorial (registre officiel). Sur les cas testés, les dernières publications indexées datent de 2016 : au-delà, l'API ne renvoie aucune donnée plus récente.

Source

Publications du Mémorial (registre officiel luxembourgeois)

Dernière donnée observée

2016 (gazette_notice_delegate, 23/03/2016)

Conséquence

Toute question sur un fait postérieur à 2016 reste sans réponse via ce pipeline

RÉSULTAT 1 — CAS RÉUSSI

« EUROPEAN FUND FOR ENERGY »

Question : existe-t-il une date à partir de laquelle le fonds n'accepte plus d'investisseurs ? Réponse trouvée après lecture des 3 chunks de statements, avec sa source citee.

```python
if __name__ == "__main__":
    result = process_client_request(
      "y a t elle une date ou EUROPEAN FUND FOR ENERGY n'accepte plus d'investisseurs?"
    )
    print(json.dumps(result, ensure_ascii=False, indent=2))
```


```
{
  "status": "answered",
  "company_number": "B149221",
  "answer": "Yes, the fund's Articles establish a 'Final Closing' concept – the date after which no additional investors may be admitte
  "source": "get_statements_comp",
  "chunks_used": 3,
  "total_chunks": 3
}
```


Réponse finale du pipeline — source : get_statements_comp

RÉSULTAT 2 — CAS FILTRÉ

« BALKAN FOOD SARL »

Question : qui est le directeur de BALKAN FOOD SARL ? L'entreprise est identifiée comme B2C (restauration) : le pipeline s'arrête immédiatement et ne consomme pas de ressources inutiles.

```
# ============================================================
# 7. TEST
# ============================================================
if __name__ == "__main__":
    result = process_client_request(
      "qui est le directeur de BALKAN FOOD SARL?"
    )
    print(json.dumps(result, ensure_ascii=False, indent=2))
```

```
{
  "status": "not_b2b",
  "company_number": "B145446",
  "message": "Cette entreprise n'est pas B2B, nous ne pouvons pas traiter cette demande."
}
```

Réponse finale du pipeline — status : not_b2b

BILAN

Ce que ce stage m'a apporté

- Orchestrer plusieurs LLM (Ollama, SerpApi/Google AI Mode, NVIDIA) dans un seul agent
- Exploiter une API métier réelle (OpenCorporates) pour des données d'entreprises
- Tracer et déboguer un pipeline complet avec LangSmith
- Concevoir un raisonnement itératif (chunk par chunk) pour traiter de gros volumes de données

Merci

Merci pour l'opportunité de stage, le choix de ce sujet et le temps que vous m'avez accordé — cela m'a permis d'apprendre, d'évoluer et de travailler avec de nouvelles technologies.

INPT × 3LM Solutions, Tunisie